

Lista de Exercícios II: Tipos de Variáveis e Estatísticas Descritivas

MQ101 — Aula Prática (R + RStudio)

Prof. Ricardo Ceneviva

Universidade Federal do ABC (UFABC) — PPG em Políticas Públicas

1 de outubro de 2025

Orientações gerais

Objetivo geral. Aplicar, no R, a identificação de tipos de variáveis e o cálculo/visualização de estatísticas descritivas básicas.

Público. Pós-graduação, iniciantes em estatística aplicada.

Entrega. Script `aula03_pratica.R` ou arquivo `.Rmd` com respostas, gráficos e comentários breves.

1 Preparação do ambiente (10 min)

1. Abrir o RStudio. Criar um projeto: *File > New Project > New Directory > New Project*.
2. Criar uma pasta `data/` no projeto.
3. Carregar pacotes:

```
1 install.packages(c("tidyverse", "readr"))
2 library(tidyverse)
3 options(scipen = 999) # evita notao cientfica
```

2 Base de dados (contexto e dicionário) (10 min)

Usaremos um CSV fornecido em aula: `educ_saude.csv` (salve em `data/`). Cada linha é uma pessoa adulta entrevistada.

Variáveis (exemplos):

- `id` (identificador, texto)

- sexo (F/M) — *qualitativa nominal*
- escolaridade (Fundamental/Médio/Superior) — *qualitativa ordinal*
- rede_escolar (pública/privada) — *qualitativa nominal*
- idade (anos) — *quantitativa contínua*
- faltas_esc (nº faltas no último mês) — *quantitativa discreta*
- tempo_estudo_h (horas por semana) — *quantitativa contínua*
- pressao_sistolica (mmHg) — *quantitativa contínua*
- diagnostico (“sem”, “HAS”, “DM”, “outros”) — *qualitativa nominal*
- plano_saude (SUS/privado/ambos/nenhum) — *qualitativa nominal*

Tarefa 1. Importação e inspeção

```
1 dados <- readr::read_csv("data/educ_saude.csv")
2 glimpse(dados)
3 summary(dados)
```

Verifique: número de linhas/colunas; classes das variáveis; existência de NA.

3 Classificação de variáveis (15 min)

Tarefa 2. Classifique e ajuste tipos

1. Faça uma tabela (no seu script) indicando o *tipo teórico* de cada variável (nominal, ordinal, discreta, contínua).
2. No R, assegure coerência entre tipo teórico e classe:

```
1 dados <- dados |>
2   mutate(
3     sexo          = factor(sexo),
4     rede_escolar  = factor(rede_escolar),
5     plano_saude   = factor(plano_saude),
6     diagnostico   = factor(diagnostico),
7     escolaridade  = factor(escolaridade,
8                           levels = c("Fundamental", "Mdio", "Superior"),
9                           ordered = TRUE)
10  )
11 str(dados)
```

3. Registre, em comentários, *por que* cada variável é daquele tipo.

4 Variáveis qualitativas — frequências e gráficos (20 min)

Tarefa 3A. Frequências absolutas e relativas

```
1 tab_plano <- table(dados$plano_saude)
2 prop_plano <- prop.table(tab_plano)
3 cbind(FA = tab_plano, FR = round(100 * prop_plano, 1))
```

Interprete: qual categoria é a *moda*? Qual a *proporção* dominante?

Tarefa 3B. Gráfico de barras (qualitativa nominal)

```
1 dados |>
2   count(plano_saude) |>
3   ggplot(aes(x = plano_saude, y = n)) +
4   geom_col() +
5   labs(x = "Plano de sade", y = "Frequencia",
6        title = "Distribuio de plano de sade")
```

Tarefa 3C. Barras ordenadas (qualitativa ordinal)

```
1 dados |>
2   count(escolaridade) |>
3   ggplot(aes(x = escolaridade, y = n)) +
4   geom_col() +
5   labs(x = "Escolaridade (ordem substantiva)", y = "Frequencia")
```

Explique por que a *ordem* importa para interpretar a distribuição.

5 Variáveis quantitativas — medidas e distribuição (25 min)

Escolha duas variáveis: idade e pressao_sistolica.

Tarefa 4A. Tendência central e dispersão

```
1 sumario_idade <- dados |>
2   summarise(
3     n      = sum(!is.na(idade)),
4     media  = mean(idade, na.rm = TRUE),
5     mediana= median(idade, na.rm = TRUE),
6     min    = min(idade, na.rm = TRUE),
7     max    = max(idade, na.rm = TRUE),
8     dp     = sd(idade, na.rm = TRUE)
```

```

9   )
10  sumario_idade

```

Repita para `pressao_sistolica`. Compare média vs. mediana. Há assimetria?

Tarefa 4B. Histograma e boxplot

```

1  ggplot(dados, aes(x = idade)) +
2    geom_histogram(bins = 20) +
3    labs(title = "Histograma de Idade")
4
5  ggplot(dados, aes(y = idade)) +
6    geom_boxplot() +
7    labs(title = "Boxplot de Idade")

```

Interprete forma, caudas e *outliers*. Repita para `pressao_sistolica`.

6 Tabelas cruzadas e resumos por grupo (15 min)

Tarefa 5A. Cruzando duas qualitativas

```

1  tab_cross <- table(dados$diagnostico, dados$plano_saude)
2  tab_cross
3  round(100 * prop.table(tab_cross, margin = 2), 1) # % por coluna (plano)

```

Qual diagnóstico é mais prevalente *dentro* de cada tipo de plano?

Tarefa 5B. Resumo de quantitativa por grupo

```

1  dados |>
2    group_by(sexo) |>
3    summarise(
4      n          = n(),
5      media_idade = mean(idade, na.rm = TRUE),
6      dp_idade    = sd(idade, na.rm = TRUE),
7      mediana_idade = median(idade, na.rm = TRUE)
8    )

```

Compare idade por sexo e por escolaridade. Comente diferenças.

7 Valores ausentes e outliers (10 min)

Tarefa 6A. Ausentes

```

1  colSums(is.na(dados))

```

Mostre resultados *com* e *sem* NA. Explique `na.rm=TRUE`.

Tarefa 6B. Outliers (regra do IQR)

```
1 Q      <- quantile(dados$tempo_estudo_h, probs = c(.25, .75), na.rm = TRUE)
2 IQRv   <- IQR(dados$tempo_estudo_h, na.rm = TRUE)
3 lim_inf <- Q[1] - 1.5 * IQRv
4 lim_sup <- Q[2] + 1.5 * IQRv
5 subset_out <- dados |>
6   filter(tempo_estudo_h < lim_inf | tempo_estudo_h > lim_sup)
7 nrow(subset_out); head(subset_out)
```

Discuta: outliers são erros, casos raros ou informação válida?

8 Exercícios aplicados (educação e saúde) (15 min)

Educação

- Distribuição de `rede_escolar` (FA/FR).
- Compare `tempo_estudo_h` por escolaridade com *boxplots*.
- Interprete: há padrão monotônico com a ordem da escolaridade?

Saúde

- Histograma de `pressao_sistolica` e reporte média/mediana/DP.
- Cruzamento `diagnostico` × `plano_saude` (% por coluna).
- Interprete: qual diagnóstico é mais prevalente em cada plano?

9 Desafio (opcional)

Crie uma **tabela-síntese** por escolaridade com:

- n , média e mediana de `idade`, DP, mínimo e máximo;
- FA/FR de `plano_saude` *dentro* de cada escolaridade.

Produza dois gráficos:

- Barras empilhadas de `plano_saude` por escolaridade (proporções).
- Boxplot de `tempo_estudo_h` por escolaridade.

Dica: use `group_by()`, `summarise()`, `count()`, `mutate(prop = n/sum(n))` e `position = "fill"` no `geom_col`.

Critérios de entrega (checklist)

- ☐ Script funcional (`.R` ou `.Rmd`) com comentários curtos explicando decisões.

- ☐ Tabelas de **frequência** (FA/FR) para ao menos **2 variáveis qualitativas**.
- ☐ **Média, mediana, mínimo, máximo, DP** para ao menos **2 variáveis quantitativas**.
- ☐ **Histogramas e boxplots** para ao menos **1 variável quantitativa**.
- ☐ **Tabelas cruzadas** entre duas qualitativas e **resumo por grupo** para uma quantitativa.
- ☐ Tratamento explícito de **NA** e comentário sobre **outliers**.
- ☐ Interpretações claras (2–3 linhas por item), sem jargão desnecessário.

Nome do arquivo: Sobrenome_Nome_Aula03_Prática.R ou .Rmd.

Prazos e submissão: conforme instruções da disciplina.